



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Magistrale in Informatica

Corso di Statistica ed Analisi dei Dati

MIT-BIH Arrhythmia Report

Autori:

Marco Greco

Mat. NF22500100

Giuseppe Gambardella

Mat. NF22500153

Repository GitHub:

github.com/Gmarco2706/mit-bih-db

ANNO ACCADEMICO 2025/2026

INDICE

1	Introduzione e Obiettivi	1
1.1	Introduzione e contesto	1
1.2	Obiettivi e Domande di Ricerca	1
2	Estrazione e Pulizia dei Dati	3
2.1	Costruzione, Caricamento e Analisi Preliminare dei Dati	3
2.1.1	Importazione in R e Verifica Integrità	3
2.1.2	Selezione del Sottocampione Omogeneo (MLII e V1)	4
2.2	Pre-processing del Segnale e Segmentazione	5
2.2.1	Rimozione della Baseline Wander	5
2.2.2	Allineamento dei Picchi e Segmentazione (Windowing)	7
2.3	Feature Extraction	8
2.4	Analisi Esplorativa delle Feature Statistiche	9
2.4.1	Analisi delle Distribuzioni	9
2.4.2	Rilevazione degli Outlier e Pulizia del Dataset	12
2.4.3	Criticità del filtraggio	15
2.4.4	Analisi delle Correlazioni Inter-canale	17
3	Clustering	22
3.1	Analisi di Clustering	22
3.1.1	Riduzione della Dimensionalità (PCA)	22
3.1.2	Configurazione e Risultati del DBSCAN	23
3.1.3	Visualizzazione della Distribuzione nello Spazio PCA	24
3.1.4	Analisi Morfologica dei Centroidi	26
3.1.5	Risposta alla RQ1	26
4	Analisi Forense	28
4.1	Validazione Forense e Analisi dei Candidati Falsi Negativi	28
4.1.1	Formulazione delle Ipotesi Statistiche e Metodologia Non Parametrica	28
4.1.2	Considerazioni sulle Distribuzioni e Calcolo dei Quantili	29
4.1.3	Analisi dei Risultati e Ispezione Visiva	29
4.1.4	Risposta alla RQ2	31

5	Generazione dei dati sintetici	32
5.1	Generazione e Validazione dei Modelli Generativi (GPT-5)	32
6	Conclusioni	42
6.1	Conclusioni e Risultati dell'Analisi	42
6.1.1	Risultati del Clustering e Caratterizzazione	42
6.1.2	Efficacia della Scansione Forense	42
6.1.3	Performance dei Modelli Generativi	43

CAPITOLO 1

INTRODUZIONE E OBIETTIVI

1.1 Introduzione e contesto

Il presente progetto basa la sua analisi sui segnali elettrocardiografici estratti dal **MIT-BIH Arrhythmia Database**, una risorsa di riferimento internazionale distribuita da PhysioNet e considerata il *gold standard* per la validazione di algoritmi di aritmia. Il dataset è costituito da **48 registrazioni ECG ambulatoriali** a due canali, ciascuna della durata di circa 30 minuti, acquisite da un campione eterogeneo di 47 soggetti (25 uomini e 22 donne, di età compresa tra i 23 e gli 89 anni). Circa il 60% delle registrazioni proviene da pazienti ricoverati. I segnali originali sono stati registrati in formato analogico e successivamente digitalizzati con una frequenza di campionamento di **360 Hz** per canale, con una risoluzione di 11 bit su un intervallo di 10 mV. La configurazione delle derivazioni è stata scelta per massimizzare le informazioni morfologiche:

- Il **canale superiore** è quasi sempre una derivazione modificata di **Lead II (MLII)**, ottenuta posizionando gli elettrodi sul torace; questa vista è ideale per il rilevamento dei complessi QRS e l'analisi del ritmo cardiaco.
- Il **canale inferiore** è tipicamente una derivazione precordiale **V1** (talvolta V2, V4 o V5), fondamentale per distinguere l'origine delle battiti ectopici e le anomalie di conduzione ventricolare.

Un aspetto cruciale del dataset è la presenza di annotazioni dettagliate fornite da cardiologi indipendenti, che fungono da *ground truth*. Il database comprende un'ampia varietà di ritmi, includendo sia battiti fisiologici ("Normal Sinus Rhythm") che eventi patologici complessi, con un focus particolare sull'**extrasistole ventricolare** (PVC - *Premature Ventricular Contraction*).

1.2 Obiettivi e Domande di Ricerca

L'obiettivo primario del presente progetto è l'analisi esplorativa e la caratterizzazione morfologica dei battiti cardiaci estratti dal dataset MIT-BIH, con un focus specifico sulle **Contrazioni Ventricolari Premature (PVC)**. Lo studio si propone di

investigare la struttura interna di questa classe patologica, superando la semplice classificazione binaria, per identificare sottogruppi o pattern ricorrenti (cluster) che possano suggerire diverse tipologie morfologiche o variabilità inter-soggetto. Parallelamente, il lavoro persegue un obiettivo di *Quality Assurance* del dato: sfruttando le caratteristiche apprese dai cluster dei battiti patologici, si intende analizzare il gruppo di battiti etichettati come "Normali" per rilevare potenziali **falsi negativi** (battiti PVC erroneamente classificati come normali nelle annotazioni originali o rumorosi al punto da sembrare tali). Gli obiettivi specifici sono formalizzati attraverso le seguenti **Research Questions (RQ)**:

- **RQ1:** *È possibile individuare diverse famiglie di PVC e raggrupparle in base alla loro morfologia tramite tecniche di clustering?*

Questa domanda mira a valutare se le feature estratte siano sufficientemente discriminanti da raggruppare spontaneamente le PVC in base alla loro forma d'onda (es. ampiezza del QRS, pendenza dell'onda T).

- **RQ2:** *È possibile rilevare, all'interno del gruppo di battiti "Normali", eventuali falsi negativi?*

Questa domanda mira a mettere in discussione la *ground truth* di partenza, operando come un sistema di *Anomaly Detection*. L'obiettivo è evidenziare battiti che, pur essendo etichettati come sani, presentano una similarità sospetta dai parametri della classe normale e un'affinità con i cluster patologici.

CAPITOLO 2

ESTRAZIONE E PULIZIA DEI DATI

2.1 Costruzione, Caricamento e Analisi Preliminare dei Dati

La pipeline di gestione dei dati è iniziata con una fase di estrazione e organizzazione implementata in Python, necessaria per strutturare le informazioni contenute nel database originale in un formato tabellare idoneo all'analisi statistica. Lo script sviluppato, `dataset.py`, sfrutta la libreria `wfdb` per iterare sui 48 record e sui corrispondenti file di annotazione (`.atr`). Il processo di costruzione del dataset ha seguito i seguenti step:

- **Estrazione delle Annotazioni:** Per ogni record, lo script ha acceduto ai file `.atr` per recuperare le etichette di classificazione (es. 'N', 'V') e i relativi indici temporali (`sampleIndex`) associati a ciascun battito.
- **Filtraggio e Mappatura:** Sono stati selezionati esclusivamente i simboli relativi ai battiti cardiaci di interesse, scartando annotazioni ausiliarie, e associati puntualmente al loro riferimento temporale nel segnale.
- **Integrazione dei Metadati:** A ogni osservazione sono state aggiunte le variabili demografiche e cliniche del paziente, quali età, sesso e farmaci assunti.

L'output di questa procedura è il file `mit_bih_dataset_puro.csv`, che rappresenta la base dati grezza del progetto.

2.1.1 Importazione in R e Verifica Integrità

Successivamente, il dataset è stato importato in ambiente **R** per la fase di analisi. Le osservazioni sono state ordinate gerarchicamente per identificativo paziente e indice temporale, garantendo la sequenzialità cronologica fondamentale per il trattamento delle serie storiche. A seguito dell'importazione, è stata effettuata una verifica di integrità sui valori mancanti (NULL) per mappare la disponibilità effettiva dei canali ECG. Questa analisi preliminare è risultata cruciale, poiché il database MIT-BIH non presenta una configurazione uniforme delle derivazioni per tutti i soggetti. La Tabella 2.1 riporta il conteggio dei campioni validi per ogni canale. Si osserva che:

2.1. COSTRUZIONE, CARICAMENTO E ANALISI PRELIMINARE DEI DATI

- Ogni registrazione completa è composta da **650.000 campioni** per canale.
- La derivazione **MLII** è presente nella quasi totalità dei soggetti (ad eccezione dei pazienti 102 e 104).
- Il secondo canale varia significativamente: mentre la maggioranza presenta la derivazione **V1**, alcuni soggetti (es. 100, 103, 117) dispongono invece di V2, V4 o V5.

Tabella 2.1: Disponibilità dei campioni per canale e per paziente. I valori indicano il numero di osservazioni non-nulle; “0” indica l’assenza del canale nella registrazione.

Pz	MLII	V1	V2	V4	V5	Pz	MLII	V1	V2	V4	V5
100	650k	0	0	0	650k	201	650k	650k	0	0	0
101	650k	650k	0	0	0	202	650k	650k	0	0	0
102	0	0	650k	0	650k	203	650k	650k	0	0	0
103	650k	0	650k	0	0	205	650k	650k	0	0	0
104	0	0	650k	0	650k	207	650k	650k	0	0	0
105	650k	650k	0	0	0	208	650k	650k	0	0	0
106	650k	650k	0	0	0	209	650k	650k	0	0	0
107	650k	650k	0	0	0	210	650k	650k	0	0	0
108	650k	650k	0	0	0	212	650k	650k	0	0	0
109	650k	650k	0	0	0	213	650k	650k	0	0	0
111	650k	650k	0	0	0	214	650k	650k	0	0	0
112	650k	650k	0	0	0	215	650k	650k	0	0	0
113	650k	650k	0	0	0	217	650k	650k	0	0	0
114	650k	0	0	0	650k	219	650k	650k	0	0	0
115	650k	650k	0	0	0	220	650k	650k	0	0	0
116	650k	650k	0	0	0	221	650k	650k	0	0	0
117	650k	0	650k	0	0	222	650k	650k	0	0	0
118	650k	650k	0	0	0	223	650k	650k	0	0	0
119	650k	650k	0	0	0	228	650k	650k	0	0	0
121	650k	650k	0	0	0	230	650k	650k	0	0	0
122	650k	650k	0	0	0	231	650k	650k	0	0	0
123	650k	0	0	0	650k	232	650k	650k	0	0	0
124	650k	0	0	650k	0	233	650k	650k	0	0	0
200	650k	650k	0	0	0	234	650k	650k	0	0	0

2.1.2 Selezione del Sottocampione Omogeneo (MLII e V1)

Dall’analisi preliminare sulla disponibilità dei canali è emersa una eterogeneità nella configurazione delle derivazioni che potrebbe introdurre un *bias* sistematico nell’analisi morfologica. Confrontare segnali provenienti da derivazioni anatomiche differenti (es. V1 vs V5) all’interno dello stesso modello statistico porterebbe a risultati inconsistenti. Per garantire la robustezza dell’analisi e la coerenza delle feature estratte, è stato applicato un criterio di inclusione rigido:

- **Criterio di Inclusione:** Presenza simultanea delle derivazioni **MLII** (canale superiore) e **V1** (canale inferiore).
- **Criterio di Esclusione:** Assenza di uno dei due canali o presenza di derivazioni alternative (V2, V4, V5).

L’applicazione di questo filtro ha comportato l’esclusione di 8 pazienti (100, 102, 103, 104, 114, 117, 123, 124), riducendo il dataset da 48 a **40 soggetti**. La Tabella 2.2 mostra il sottocampione finale utilizzato per il resto dello studio, garantendo una base dati perfettamente omogenea (650.000 campioni per canale per tutti i soggetti selezionati).

Tabella 2.2: Dataset filtrato: lista dei 40 pazienti che presentano la configurazione standard MLII + V1. Gli altri canali (V2, V4, V5) sono assenti (valore 0).

Pz	MLII	V1	V2	V4	V5	Pz	MLII	V1	V2	V4	V5
101	650k	650k	0	0	0	207	650k	650k	0	0	0
105	650k	650k	0	0	0	208	650k	650k	0	0	0
106	650k	650k	0	0	0	209	650k	650k	0	0	0
107	650k	650k	0	0	0	210	650k	650k	0	0	0
108	650k	650k	0	0	0	212	650k	650k	0	0	0
109	650k	650k	0	0	0	213	650k	650k	0	0	0
111	650k	650k	0	0	0	214	650k	650k	0	0	0
112	650k	650k	0	0	0	215	650k	650k	0	0	0
113	650k	650k	0	0	0	217	650k	650k	0	0	0
115	650k	650k	0	0	0	219	650k	650k	0	0	0
116	650k	650k	0	0	0	220	650k	650k	0	0	0
118	650k	650k	0	0	0	221	650k	650k	0	0	0
119	650k	650k	0	0	0	222	650k	650k	0	0	0
121	650k	650k	0	0	0	223	650k	650k	0	0	0
122	650k	650k	0	0	0	228	650k	650k	0	0	0
200	650k	650k	0	0	0	230	650k	650k	0	0	0
201	650k	650k	0	0	0	231	650k	650k	0	0	0
202	650k	650k	0	0	0	232	650k	650k	0	0	0
203	650k	650k	0	0	0	233	650k	650k	0	0	0
205	650k	650k	0	0	0	234	650k	650k	0	0	0

2.2 Pre-processing del Segnale e Segmentazione


Una volta definito il sottocampione omogeneo di 40 pazienti, il flusso di lavoro si è concentrato sulla pulizia del segnale e sulla creazione delle unità statistiche fondamentali (i singoli battiti) da sottoporre ad analisi.

2.2.1 Rimozione della Baseline Wander


I segnali ECG ambulatoriali sono fisiologicamente affetti da rumore a bassa frequenza, noto come *Baseline Wander* (Deriva della Linea di Base), causato principalmente dalla respirazione e dai movimenti del paziente. Questo artefatto sposta il livello isoelettrico (lo "zero") del segnale, alterando le ampiezze relative e compromettendo le successive analisi morfologiche.

Per correggere questo fenomeno è stato applicato un filtro basato sulla statistica robusta:

- È stata calcolata la **mediana mobile** del segnale su una finestra temporale di **0.8 secondi**.
- Tale componente a bassa frequenza è stata sottratta dal segnale originale, riportando l'isoelettrica a zero e stabilizzando il tracciato.
- L'operazione è stata eseguita in modo indipendente per ciascun paziente e per ciascun canale (MLII e V1).



(a) Segnale grezzo con deriva della linea di base




(b) Segnale stabilizzato (Mediana Mobile sottratta)

2.2.2 Allineamento dei Picchi e Segmentazione (Windowing)

Le annotazioni originali del database MIT-BIH indicano la presenza di un battito, ma l'indice temporale fornito non coincide sempre perfettamente con il picco R (il punto di massima depolarizzazione). Per garantire un allineamento preciso, è stata implementata una procedura di **raffinamento dei picchi**:

1. Dalle annotazioni originali vengono filtrate le posizioni dei soli battiti di classe **N** (Normali) e **V** (PVC).
2. Per ogni annotazione, l'algoritmo ricerca il **massimo assoluto** del segnale sul canale MLII (derivazione di riferimento) all'interno di un intorno di **30 campioni**.
3. L'indice temporale viene aggiornato alla posizione del nuovo massimo trovato.



(a) Annotazione originale (spesso disallineata rispetto al massimo locale).

(b) Annotazione raffinata (centrata sul massimo assoluto del QRS).

Figura 2.2: Dettaglio della procedura di allineamento dei picchi. Si nota come la correzione (b) garantisca che il centro della finestra di segmentazione coincida perfettamente con l'apice dell'onda R

Infine, si è proceduto alla segmentazione vera e propria. Per ogni picco corretto, è stata estratta una finestra fissa di **201 campioni** centrata sul picco (100 campioni prima, il picco, 100 campioni dopo). Il risultato di questa fase sono matrici di dati separate per classe (N e V) e per canale; in questo stadio vengono definitivamente scartati i segmenti che presentano valori mancanti o incompleti (ad esempio a inizio/fine registrazione). A conclusione della procedura di estrazione e allineamento temporale, il dataset risulta così composto:

- **Battiti Normali (N):** 65.569
- **Battiti Ventricolari (V):** 7.029




Figura 2.3: Risultato della segmentazione: finestre temporali di 201 campioni estratte e allineate per le classi Normale (N) e PVC (V). Si nota la coerenza morfologica all'interno delle classi e la netta distinzione tra le due forme d'onda.

2.3 Feature Extraction

L'estrazione delle feature statistiche è stata introdotta per integrare i dati morfologici (segnali grezzi) nel clustering con parametri aggiuntivi e per permettere lo studio delle relative distribuzioni. L'operazione viene eseguita applicando una funzione dedicata (`estrai_features_statistiche`) che agisce riga per riga sulle matrici segmentate. Poiché ogni riga rappresenta un singolo battito (finestra temporale di 201 campioni), vengono calcolati i seguenti descrittori descrittivi:

- **Media (μ):** Il valore medio dei campioni all'interno della finestra temporale (`rowMeans`).
- **Deviazione Standard (σ):** Misura la dispersione dei valori del segnale, indicativa dell'energia e della variabilità del battito.

- **Skewness (Asimmetria):** Misura il grado di asimmetria della distribuzione dei campioni rispetto alla media, utile per identificare distorsioni nella forma d'onda.
- **Kurtosis (Curtosi):** Quantifica la "pesantezza" delle code della distribuzione; questo parametro è particolarmente rilevante per distinguere la morfologia "appuntita" dei battiti normali da quella più larga e smussata delle PVC.
- **Ampiezza Massima (Range):** Definita come l'escursione totale del segnale all'interno della finestra, calcolata come la differenza tra il valore massimo e il valore minimo ($\max(x) - \min(x)$).

Questa procedura viene applicata separatamente per ciascuna combinazione di classe e derivazione, producendo in output quattro strutture distinte di feature:

1. Battiti Normali (N) su MLII;
2. Battiti Normali (N) su V1;
3. Battiti PVC (V) su MLII;
4. Battiti PVC (V) su V1.


2.4 Analisi Esplorativa delle Feature Statistiche

Al fine di caratterizzare la struttura statistica dei battiti, con particolare attenzione alla classe ventricolare (PVC), e garantire la robustezza del dataset per le successive fasi di clustering, è stata implementata una pipeline di analisi composta da tre fasi distinte: ispezione distributiva, rimozione degli artefatti e analisi delle dipendenze tra le derivazioni.

2.4.1 Analisi delle Distribuzioni


Inizialmente, sono state esaminate le distribuzioni delle feature statistiche estratte (*Max Amplitude*, *Skewness*, *Kurtosis*) per entrambe le derivazioni (*MLII* e *V1*). Attraverso l'ausilio di istogrammi e boxplot, è stato effettuato un confronto tra la popolazione dei battiti Normali (*N*) e quella dei battiti Ventricolari (*V*). Questa analisi visuale ha permesso di valutare la dispersione dei dati e di evidenziare la presenza di valori estremi (*outlier*) che si discostano significativamente dal range fisiologico atteso per la morfologia del complesso QRS.

MLII: Struttura interna dei battiti PVC (V)



(a) Distribuzione delle feature statistiche per battiti PVC (Derivazione MLII)


V1: Struttura interna dei battiti PVC (V)



(b) Distribuzione delle feature statistiche per battiti PVC (Derivazione V1)


Figura 2.4: Analisi delle distribuzioni per la classe Ventricolare (V). Si notano le differenze di asimmetria e curtosi tra le due derivazioni.

MLII: Struttura interna dei battiti NORMALI (N)



(a) Distribuzione feature per battiti NORMALI (MLII)

V1: Struttura interna dei battiti NORMALI (N)



(b) Distribuzione feature per battiti NORMALI (V1)

Tabella 2.3: Caratteristiche statistiche iniziali delle feature estratte dai battiti PVC (7.029 segmenti).

Derivazione	Feature	Media (μ)	Dev. Std. (σ)
MLII	Ampiezza Max	2,655	0,899
	Skewness	0,374	1,162
	Kurtosis	1,261	1,423
V1	Ampiezza Max	1,702	1,007
	Skewness	-0,556	1,214
	Kurtosis	1,798	2,615

2.4.2 Rilevazione degli Outlier e Pulizia del Dataset

Per discriminare tra varianti morfologiche rare e artefatti di acquisizione (dovuti a rumore o errori di segmentazione), è stata condotta un'ispezione puntuale sui segnali grezzi corrispondenti ai valori statistici anomali. Sulla base di questa indagine, sono state definite delle soglie di taglio rigide per l'esclusione dei battiti non validi. È stata applicata una procedura di *eliminazione incrociata*: dato che ogni battito è rappresentato simultaneamente su due canali, l'identificazione di un artefatto in una singola derivazione ha comportato la rimozione dell'intero evento dal dataset. Nello specifico, sono stati esclusi i battiti che presentavano:

- **Ampiezza (*Max_Amp*):** Sono stati rimossi i valori di tensione non fisiologici, identificati come outlier estremi nei boxplot: nello specifico, valori > 6 mV (su entrambi i canali) e < 1 mV (su MLII), indicativi di saturazione o perdita di segnale.
- **Curtosi (*Kurtosis*):** Applicazione di soglie specifiche per canale, escludendo valori > 7.5 su MLII e > 15 su V1, sintomatici di artefatti impulsivi o picchi di rumore.
- **Asimmetria (*Skewness*):** Filtraggio mirato sulla derivazione V1 per eliminare morfologie eccessivamente distorte, rimuovendo i battiti con skewness > 2.5 o < -5.0 .

BOXPLOT PVC: Analisi Outliers e Differenze Canali




Figura 2.6: Analisi della dispersione tramite Boxplot: evidenza degli outlier per Ampiezza, Skewness e Kurtosis su entrambi i canali.

Al termine della procedura di filtraggio, il resoconto dell'eliminazione incrociata degli outlier per la classe dei battiti ventricolari (PVC) evidenzia una rimozione mirata di segmenti non idonei all'analisi:

- **Battiti PVC iniziali:** 7.029
- **Battiti rimossi:** 95
- **Battiti puliti:** 6.934
- **Percentuale rimossa:** 1,35%

Derivazione	Feature	Metrica	Prima	Dopo	Δ %
MLII	Ampiezza Max	Media (μ)	2,655	2,674	+0,72
		SD (σ)	0,899	0,886	-1,49
	Skewness	Media (μ)	0,374	0,376	+0,65
		SD (σ)	1,162	1,159	-0,26
	Kurtosis	Media (μ)	1,261	1,250	-0,88
		SD (σ)	1,423	1,385	-2,69
V1	Ampiezza Max	Media (μ)	1,702	1,707	+0,32
		SD (σ)	1,007	1,004	-0,37
	Skewness	Media (μ)	-0,556	-0,565	+1,58
		SD (σ)	1,214	1,201	-1,09
	Kurtosis	Media (μ)	1,798	1,772	-1,45
		SD (σ)	2,615	2,504	-4,25

Le figure seguenti mostrano gli istogrammi aggiornati per le due derivazioni analizzate.

MLII (Clean): Distribuzioni PVC dopo rimozione outlier




Figura 2.7: Distribuzione delle feature statistiche per i battiti PVC (MLII) dopo l'eliminazione incrociata.

V1 (Clean): Distribuzioni PVC dopo rimozione outlier




Figura 2.8: Distribuzione delle feature statistiche per i battiti PVC (V1) dopo l'eliminazione incrociata.

2.4.3 Criticità del filtraggio

L'applicazione dei criteri statistici basati sui boxplot, pur essendo necessaria per eliminare saturazioni e rumore, presenta un limite intrinseco: l'incapacità di distinguere tra artefatto tecnico e variante biologica estrema.

Di conseguenza, alcuni battiti che si collocavano nelle code della distribuzione sono stati rimossi inevitabilmente perché indistinguibili, a livello di feature, dagli outlier tecnici.

Di seguito vengono riportati alcuni esempi dei battiti rimossi durante la procedura di filtraggio.




Figura 2.9: Ispezione dei battiti esclusi per morfologie estreme (alta curtosi).




Figura 2.10: Dettaglio degli outlier per **Ampiezza e Curtosi** anomale.




Figura 2.11: Dettaglio degli outlier rimossi per **Curtosi estrema** (> 15 su V1).

2.4.4 Analisi delle Correlazioni Inter-canale

Infine, sul dataset depurato, è stata indagata la relazione tra le feature estratte dai due canali per verificare come le variabili statistiche si coordinino tra loro. L'obiettivo è quantificare il grado di dipendenza lineare tra le nuove variabili calcolate (Ampiezza, Skewness e Kurtosis) nelle due derivazioni.

Tramite il calcolo della matrice di correlazione e la visualizzazione di *scatter plot* incrociati, è possibile identificare se le informazioni veicolate da MLII e V1 siano ridondanti o se ogni canale fornisca un contributo informativo unico.

OB1: Struttura dipendenze Classe V

Correlazione incrociata tra le feature di MLII e V1






Figura 2.12: Matrice di correlazione incrociata tra le feature estratte dai canali MLII e V1 per la classe PVC. I coefficienti indicano la forza del legame lineare tra le diverse proprietà morfologiche.



(a) Confronto Ampiezza (Max_Amp)




(b) Confronto Skewness

Figura 2.13: Analisi scatter plot (parte 1): Ampiezza e Skewness.

OB1: Relazione Curtosi MLII vs V1 (Solo V)

Identificazione di bias di ampiezza tra le derivazioni



(c) Confronto Curtosi: MLII vs V1

Figura 2.13: Scatter plot incrociati delle feature morfologiche (MLII vs V1). (Continua da pagina precedente). La struttura non lineare delle distribuzioni conferma che le due derivazioni apportano informazioni complementari.

L'analisi visiva dei diagrammi di dispersione arricchisce l'interpretazione dei dati numerici, rivelando strutture non lineari che i soli coefficienti di correlazione non potevano evidenziare.

- **Identificazione di Cluster (Ampiezza):** Nel grafico *MLII vs V1*, la distribuzione dei punti non è uniforme ma presenta dei raggruppamenti distinti ("isole"). Oltre al nucleo principale, si osservano gruppi di battiti con alta energia su un canale e moderata sull'altro. Questo suggerisce l'esistenza di diverse morfologie di PVC che vengono separate efficacemente solo incrociando le due derivazioni.
- **Asimmetria Distributiva (Curtosi):** La relazione tra le curtosi assume una caratteristica forma a "L". Molti battiti presentano valori impulsivi elevati ("spikes") su V1 mantenendo valori bassi su MLII, e viceversa. Ciò indica che gli eventi ad alta frequenza sono spesso fenomeni locali, rilevabili da una sola vista elettrica per volta.

- **Assenza di Linearità (Skewness):** La dispersione diffusa conferma che l'asimmetria dell'onda QRS su un canale non è predittiva di quella sull'altro, rafforzando l'ipotesi di indipendenza tra le feature.

CAPITOLO 3

CLUSTERING

3.1 Analisi di Clustering

In questa sezione viene presentata la metodologia adottata per la classificazione non supervisionata dei battiti ventricolari (PVC). L'obiettivo è identificare sottogruppi morfologici omogenei (fenotipi) senza l'ausilio di etichette predefinite, basandosi esclusivamente sulla struttura intrinseca dei dati.

Il flusso di lavoro, volto a gestire la complessità e l'alta dimensionalità delle feature estratte, si articola nelle seguenti fasi operative:

- **Riduzione della Dimensionalità:** Applicazione dell'Analisi delle Componenti Principali (PCA) per comprimere lo spazio delle feature, preservando la varianza significativa ed eliminando la ridondanza informativa tra i canali.
- **Clustering Density-Based:** Utilizzo dell'algoritmo DBSCAN per raggruppare i battiti in base alla densità locale, permettendo l'identificazione di cluster di forma arbitraria e l'isolamento degli outlier (rumore).
- **Validazione e Interpretazione:** Valutazione della qualità della partizione tramite metriche interne (Silhouette Score) e analisi clinica dei centroidi (forme d'onda medie) per confermare la coerenza fisiologica dei gruppi individuati.

3.1.1 Riduzione della Dimensionalità (PCA)

Per gestire l'elevata dimensionalità dello spazio delle feature (composto da vettori di forma normalizzati e parametri statistici per entrambi i canali), è stata applicata l'Analisi delle Componenti Principali (PCA). L'obiettivo era comprimere l'informazione morfologica riducendo il rumore e la ridondanza.

Dall'analisi della varianza spiegata (output console), è emerso che le prime componenti catturano la gran parte dell'informazione strutturale del segnale:

- La prima componente (PC1) spiega da sola il 32.41% della varianza.
- Le prime 3 componenti raggiungono il 54.79%.

- La soglia del **95% di varianza cumulativa** viene superata con la **21^a componente** (95.16%).

Tabella 3.1: Dettaglio della varianza spiegata dalle Componenti Principali.

Componente	Dev. Std (σ)	Var. Spiegata (%)	Var. Cumulativa (%)
PC1	11.50	32.41	32.41
PC2	6.92	11.72	44.13
PC3	6.59	10.65	54.79
PC4	5.68	7.90	62.69
PC5	5.08	6.33	69.01
PC10	3.21	2.53	86.51
PC15	1.84	0.83	91.76
PC20	1.37	0.46	94.77
PC21	1.26	0.39	95.16

Di conseguenza, lo spazio di input per l'algoritmo di clustering è stato ridotto alle prime 21 Componenti Principali ($PCA_COMPS = 21$).

3.1.2 Configurazione e Risultati del DBSCAN

Per l'identificazione dei gruppi morfologici è stato utilizzato l'algoritmo *DBSCAN* (Density-Based Spatial Clustering of Applications with Noise), scelto per la sua capacità di gestire cluster di forma arbitraria e di isolare il rumore (outlier). I parametri dell'algoritmo sono stati determinati empiricamente per adattarsi alla specifica densità dei dati proiettati nello spazio PCA:

- **MinPts** ($k = 42$): Il valore della densità minima è stato impostato seguendo la regola euristica $MinPts \approx 2 \cdot dim$, dove $dim = 21$ corrisponde al numero di componenti principali utilizzate. Un valore così elevato è necessario in spazi ad alta dimensionalità per garantire la formazione di cluster significativi e ridurre la frammentazione dovuta al rumore.
- **Epsilon** ($\varepsilon = 8.2$): Il raggio di vicinato è stato calibrato sperimentalmente tramite l'ispezione visiva della distribuzione spaziale dei punti (3D plot). Il valore scelto rappresenta il miglior compromesso per separare i nuclei densi senza fondere cluster adiacenti ma morfologicamente distinti.

L'algoritmo ha identificato **16 cluster distinti**. La procedura ha classificato come "rumore" (label 0) 1.709 battiti, pari al **24.6%** del dataset. Tale percentuale, sebbene significativa, indica un filtraggio conservativo: il sistema ha scartato battiti con morfologie ambigue o di transizione, privilegiando la coerenza interna dei gruppi formati.

Validazione delle Metriche

La qualità della partizione è stata valutata tramite metriche quantitative:

- **Silhouette Score Medio** ($S = 0.39$): Calcolato escludendo il rumore, questo valore indica una discreta separabilità dei cluster. Considerando l'elevata dimensionalità (21D) e la natura non convessa dei gruppi fisiologici, un valore prossimo a 0.4 conferma che i cluster trovati possiedono una struttura interna coerente.
- **Distribuzione della Popolazione**: I cluster non sono equi-popolati, riflettendo la naturale prevalenza di alcune morfologie PVC rispetto ad altre più rare o patologiche. Come dettagliato in Tabella 3.2, il **Cluster 7** risulta dominante (1.528 battiti), aggregando la morfologia più comune, seguito dai Cluster 4 e 1. I gruppi minori (es. Cluster 9, 3) rappresentano verosimilmente varianti ectopiche rare.

Tabella 3.2: Dettaglio della numerosità dei 16 cluster identificati (ordinati per frequenza decrescente).

Rank	Cluster ID	Numero di Battiti
1	7	1.528
2	4	675
3	1	643
4	16	493
5	6	447
6	14	273
7	15	213
8	12	175
9	2	153
10	13	129
11	11	128
12	5	107
13	10	90
14	8	75
15	3	51
16	9	45


3.1.3 Visualizzazione della Distribuzione nello Spazio PCA

Per verificare qualitativamente la coerenza della partizione ottenuta, i risultati del clustering sono stati proiettati nello spazio tridimensionale definito dalle prime tre Componenti Principali (PC1, PC2, PC3), che cumulativamente spiegano oltre il 54% della varianza totale.

La Figura 3.1 illustra la distribuzione spaziale dei battiti:

- **Separabilità**: Si osserva chiaramente come i diversi cluster (rappresentati da colori differenti) occupino regioni distinte dello spazio latente. Sebbene vi siano zone di prossimità, i nuclei densi ("core points") di ciascun gruppo appaiono ben separati, giustificando la capacità del DBSCAN di discriminare le diverse morfologie.

- **Densità Variabile:** La struttura dei dati non è sferica (come assunto da algoritmi tipo K-Means), ma presenta forme allungate e irregolari. I cluster più numerosi (es. Cluster 7) formano nubi dense e compatte, mentre i cluster minori appaiono come raggruppamenti periferici più sparsi.
- **Rumore:** I punti non assegnati (etichettati come rumore) si disperdono nelle zone di transizione a bassa densità tra un cluster e l'altro, confermando il ruolo del filtro nel rimuovere battiti ambigui che avrebbero "sporcato" la definizione dei centroidi.



(a) Vista d'insieme dello spazio PCA

Figura 3.1: Visualizzazione grafica dei cluster identificati. Proiezione 3D dei battiti nello spazio delle prime tre Componenti Principali.

3.1.4 Analisi Morfologica dei Centroidi

L'ispezione visiva dei centroidi (Figura 3.2), che rappresentano la "forma media" di ogni cluster, conferma l'efficacia della separazione. L'uso congiunto di MLII e V1 ha permesso di distinguere pattern che apparirebbero identici osservando un solo canale.

Dall'analisi della Figura 3.2 emergono le seguenti osservazioni fisiologiche:

- **Opposizione di Fase (Cluster 7 vs Cluster 10):** Il **Cluster 7** (il più popoloso) mostra un picco positivo netto su MLII e un'onda negativa su V1. Al contrario, il **Cluster 10** presenta un pattern opposto, con MLII negativo e V1 positivo/bifasico. Questa distinzione suggerisce origini focali ventricolari differenti (es. ventricolo destro vs sinistro).
- **Discordanza vs Concordanza (Cluster 1 vs Cluster 11):** Il **Cluster 1** è un esempio di "concordanza negativa": entrambi i canali mostrano una profonda deflessione verso il basso (onde Q o QS profonde). Il **Cluster 11**, invece, mostra un comportamento opposto con picchi positivi concordanti su entrambi i canali.
- **Morfologie Complesse (Cluster 4 e 5):** Il **Cluster 4** è caratterizzato da un'onda bifasica su MLII e nettamente positiva su V1. Il **Cluster 5** mostra una morfologia simile su V1, ma con ampiezze e tempistiche di ripolarizzazione (onda T) differenti su MLII, dimostrando come il clustering riesca a cogliere sfumature sottili nella ripolarizzazione.
- **Varianti Rare (Cluster 14, 15, 16):** I cluster meno popolosi (es. 16) mostrano morfologie estreme, come onde molto larghe (alta durata del QRS) o pendenze ripide, che rappresentano probabilmente eventi ectopici peculiari o fusion beat ben isolati dal resto della popolazione.

In conclusione, l'approccio multivariato (21 feature PCA su 2 canali) combinato con DBSCAN ha permesso di mappare la variabilità morfologica dei battiti PVC in 16 fenotipi distinti.

3.1.5 Risposta alla RQ1

L'analisi conferma che è possibile individuare e raggruppare diverse famiglie di PVC tramite tecniche di clustering. I risultati principali lo dimostrano chiaramente:

- **Esistenza di pattern:** L'algoritmo ha isolato con successo 16 cluster differenti, provando che i battiti non sono distribuiti a caso ma formano gruppi morfologici precisi.
- **Qualità statistica:** Il Silhouette Score di 0,39 certifica che i gruppi trovati sono abbastanza compatti per essere tra di loro ben distinti.
- **Autonomia:** La combinazione di PCA (21 componenti) e DBSCAN ha permesso di mappare tutta la variabilità dei dati senza bisogno di etichette manuali, distinguendo sia le forme comuni che quelle rare.




Figura 3.2: Centroidi dei 16 cluster identificati. Le linee rappresentano l'andamento medio del segnale per i canali MLII e V1 in ciascun gruppo. Si noti la varietà delle configurazioni morfologiche.

CAPITOLO 4

ANALISI FORENSE

4.1 Validazione Forense e Analisi dei Candidati Falsi Negativi

In questa fase dell'analisi viene eseguita una revisione statistica del dataset per valutare la coerenza delle etichette originali. L'obiettivo è identificare eventuali battiti classificati come Normali (N) che presentano una segnatura morfologica e statistica indistinguibile dai cluster di PVC precedentemente individuati.

4.1.1 Formulazione delle Ipotesi Statistiche e Metodologia Non Parametrica

L'indagine forense è stata strutturata come un test di verifica d'ipotesi iterato su ogni singolo battito del gruppo di controllo (N). Il sistema decisionale si basa sulle seguenti assunzioni:

- **Ipotesi Nulla (H_0):** Il battito in esame è un vero battito Normale. La classificazione originale è corretta e le sue caratteristiche non appartengono alla popolazione statistica dei cluster PVC.
- **Ipotesi Alternativa (H_1):** Il battito è un errore di etichettatura (Falso Negativo). Esso appartiene a tutti gli effetti alla popolazione di uno dei cluster PVC individuati.

Per poter **rifiutare** H_0 , un battito deve superare contemporaneamente due barriere di controllo:

- **Isomorfismo di Forma ($r > 0.80$):** Correlazione morfologica superiore all'80% su entrambi i canali (MLII e V1) rispetto al centroide del cluster.
- **Coerenza Statistica tramite Quantili (99.7%):** Si è optato per un approccio basato sui quantili empirici. Un battito è considerato coerente solo se tutte le sue 6 feature (Ampiezza, Curtosi, Skewness sui due canali) ricadono all'interno dell'intervallo $[Q_{0.0015}, Q_{0.9985}]$ calcolato sulla distribuzione reale del cluster.

4.1.2 Considerazioni sulle Distribuzioni e Calcolo dei Quantili

L'ispezione visiva degli istogrammi ha evidenziato la naturale eterogeneità morfologica delle distribuzioni all'interno dei vari cluster. A titolo esemplificativo, in Figura 4.1 è riportato un profilo spiccatamente asimmetrico e multimodale (Cluster 1), mentre in Figura 4.2 si osserva una distribuzione più compatta e simmetrica.




Figura 4.1: Esempio di distribuzione multimodale e irregolare (Cluster 1), con sovrapposti i limiti quantilici al 99.7% (linee rosse tratteggiate).

Per definire la regione di tolleranza del test, si è proceduto all'estrazione diretta dei quantili empirici dai dati misurati. Fissando i limiti al **99.7% centrale** (escludendo unicamente lo 0.3% delle osservazioni più estreme, analogamente alla regola empirica dei 3σ per la varianza), il sistema definisce un intervallo altamente conservativo. Questa ampiezza garantisce che vengano scartati esclusivamente i valori gravemente anomali (outlier estremi), minimizzando il rischio di escludere varianti patologiche legittime.

4.1.3 Analisi dei Risultati e Ispezione Visiva

Dalla scansione sistematica dell'intero dataset di controllo ($N = 65.569$) applicando i criteri di inclusione sopra descritti, emergono i seguenti risultati:




Figura 4.2: Esempio di distribuzione compatta e simmetrica, con i relativi limiti quantilici al 99.7%.

- **Candidati V Identificati (Falsi Negativi):** 1
- **Incidenza Statistica:** 0,002%

L'algoritmo ha isolato un singolo battito (Beat ID: 3675) che ha soddisfatto matematicamente sia l'isomorfismo strutturale ($r > 0.80$) sia i requisiti quantilici al 99.7% rispetto al Cluster 7.

Tuttavia, come si evince dall'ispezione visiva riportata in Figura 4.3, il candidato è in realtà un **falso allarme (Falso Positivo) generato dall'algoritmo**, riconducibile a un normale battito sinusale (N). Il superamento dei rigorosi vincoli algoritmici in è giustificabile attraverso due specifiche dinamiche matematiche:

1. **Invarianza di scala della Correlazione:** La correlazione di Pearson valuta l'andamento del trend (sincronia delle deflessioni) ignorando l'effettiva magnitudo del segnale. Sul canale V1, il battito presenta microscopiche oscillazioni sincrone al template patologico, sufficienti a produrre un coefficiente geometrico dell'82% nonostante il palese deficit strutturale.
2. **Tolleranza delle code distributive:** L'allargamento dell'intervallo empirico al 99.7% ha generato una regione di accettazione estremamente permissiva per le feature dimensionali.




Figura 4.3: Analisi visiva dell'unico candidato isolato dal sistema. Nonostante la coerenza matematica dei parametri, l'ispezione del canale V1 rivela un'evidente assenza della morfologia tipica del cluster patologico di riferimento.

4.1.4 Risposta alla RQ2

L'analisi su 65.569 battiti ha dimostrato che:

- **Assenza di Falsi Negativi Clinici:** L'unico battito sospetto isolato matematicamente dal sistema si è rivelato, all'esame clinico-visivo, un effettivo battito Normale.
- **Validazione delle Annotazioni:** Il totale riassorbimento dell'Ipotesi Alternativa (H_1) dopo l'ispezione visiva certifica in via definitiva la robustezza e la correttezza delle annotazioni originali del dataset. Nessun battito morfologicamente e statisticamente ascrivibile alla classe PVC è sfuggito all'etichettatura originaria .

CAPITOLO 5

GENERAZIONE DEI DATI SINTETICI

5.1 Generazione e Validazione dei Modelli Generativi (GPT-5)


In questa fase conclusiva della ricerca, l'attenzione si sposta dalla caratterizzazione dei segnali clinici alla validazione della capacità sintetica dei modelli linguistici di ultima generazione. A valle della profilazione statistica condotta sui record reali, viene presentata un'analisi comparativa sistematica volta a quantificare come il livello di dettaglio informativo fornito all'IA influenzi direttamente il realismo del dato generato.

La divergenza sostanziale tra le due metodologie risiede nella natura dell'istruzione e nel perimetro di risorse messo a disposizione del modello:

- **Approccio Context-Aware:** In questa configurazione, il modello opera come un *agente esperto*. Oltre a ricevere i dati sorgente, è stato informato sulla loro precisa identità clinica (dataset MIT-BIH) e sulla specifica patologia trattata (PVC). Fondamentale è stata la possibilità del modello di consultare attivamente la letteratura accademica online, permettendogli di integrare la pura analisi dei file con le leggi fisiologiche che regolano la correlazione tra le derivazioni MLII e V1.
- **Baseline No Context:** Il modello opera in una condizione di *isolamento informativo*. La generazione è guidata da istruzioni puramente operative e meccaniche, senza alcuna consapevolezza del dominio di appartenenza. Privato della possibilità di effettuare ricerche esterne e all'oscuro della natura clinica del compito, il modello è costretto a una sintesi basata esclusivamente sui soli file caricati in sessione.


Nelle pagine seguenti, la discussione visiva segue un ordine gerarchico: per ogni metrica analizzata, viene proposta in alto la generazione *Context-Aware* e in basso la baseline *No Context*.

MLII: CONTEXT AWARE (GPT-5)




MLII: Context Aware

MLII: NO CONTEXT (GPT-5)




MLII: No Context

V1: CONTEXT AWARE (GPT-5)




V1: Context Aware


V1: NO CONTEXT (GPT-5)




V1: No Context



Ampiezza: Context Aware




Ampiezza: No Context




Kurtosis: Context Aware



Kurtosis: No Context




Skewness: Context Aware




Skewness: No Context

BOXPLOT: CONTEXT AWARE (GPT-5)




Boxplot: Context Aware


BOXPLOT: NO CONTEXT (GPT-5)



Boxplot: No Context



Correlazione: Context Aware



Correlazione: No Context


I valori numerici estratti, che confermano la convergenza del modello verso il *gold standard* MIT-BIH, sono riassunti in Tabella 5.1.

Tabella 5.1: Confronto dei valori medi estratti sui dataset sintetici e reali (MIT-BIH).

Dataset	Amp MLII	Kur MLII	Skw MLII	Amp V1	Kur V1	Skw V1
Reale (MIT-BIH)	2.655	1.261	0.374	1.702	1.798	-0.556
Context Aware	2.566	1.075	0.333	1.628	1.249	-0.446
No Context	2.785	5.153	1.076	1.838	3.611	-1.101


La validazione finale confronta le distribuzioni del modello *Context-Aware* con i dati reali del MIT-BIH.

Confronto Distribuzioni REALE vs SINTETICO - MLII
Sovrapposizione istogrammi per validazione



Distribuzioni Sintetici con context e Reali MLII

Confronto Distribuzioni REALE vs SINTETICO - V1
Sovrapposizione istogrammi per validazione



Distribuzioni Sintetiche con context e Reali V1

CAPITOLO 6

CONCLUSIONI

6.1 Conclusioni e Risultati dell'Analisi

L'analisi statistica condotta ha dimostrato l'efficacia dell'integrazione tra estrazione parametrica e modelli generativi per il trattamento dei segnali ECG. I risultati ottenuti confermano la validità delle metodologie applicate su tre livelli operativi.

6.1.1 Risultati del Clustering e Caratterizzazione

L'applicazione dell'algoritmo **DBSCAN** ha permesso di identificare una separazione dei battiti PVC in cluster basati sulla densità locale. A differenza di approcci centroid-based, il DBSCAN ha consentito di:

- Isolare automaticamente i battiti atipici come rumore (*outliers*), evitando che inquinassero la media morfologica dei gruppi principali.
- Definire dei **Template Fisiologici** basati sui punti core, dimostrando che la variabilità elettrica dei battiti patologici si concentra in regioni di densità strutturali precise e non casuali.

6.1.2 Efficacia della Scansione Forense

L'analisi forense è stata condotta per verificare la presenza di eventuali falsi negativi all'interno della classe dei battiti classificati come normali (N). Nonostante l'applicazione di criteri di scansione molto severi, i risultati hanno indicato l'assenza di PVC nascoste tra i battiti etichettati come normali. L'utilizzo combinato della correlazione di Pearson (logica *pmin*) e degli intervalli quantilici (0.15% – 99.85%) ha permesso di:

- Confermare l'affidabilità della classificazione originale del dataset, non avendo identificato battiti N con anomalie morfologiche riconducibili alle PVC.
- Validare la robustezza del sistema di filtraggio: la scansione ha operato un controllo incrociato obbligatorio su entrambi i canali (MLII e V1), isolando efficacemente il rumore clinico ed evitando che artefatti tecnici venissero scambiati per anomalie patologiche.

6.1.3 Performance dei Modelli Generativi

Il confronto diretto tra i dataset sintetici ha quantificato la superiorità dell'approccio *Context-Aware*. Mentre la baseline *No Context* ha prodotto segnali con Kurtosis anomala (fino a 5.15), l'uso di prompt contestualizzati ha portato i parametri sintetici a convergere verso i valori reali del MIT-BIH (Kurtosis 1.07),